

```
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
from sklearn.datasets import load_iris
```



Метод
градиентного
спуска. Метрики.
Нормализация.
Lasso и Ridge

Занятие 3

Как мы решаем задачу линейной регрессии?



Как мы решаем задачу линейной регрессии?

- Находим веса в уравнении $w_1x_1 + w_2x_2 + \dots + w_{n-1}x_{n-1} + w_n$
- Какую функцию минимизируем?



Как мы решаем задачу линейной регрессии?

- Находим веса в уравнении $w_1x_1 + w_2x_2 + \dots + w_{n-1}x_{n-1} + w_n$
- Какую функцию минимизируем?
- Минимизируем функционал ошибки – MSE (но можно и что-то другое)
- Формула:
$$\text{MSE} = \frac{1}{n} \sum_{i=1}^n (Y_i - \hat{Y}_i)^2$$
- Есть точное аналитическое решение:

$$w = (X^T X)^{-1} X^T y$$




Недостатки аналитического решения

- Высокая вычислительная сложность нахождения обратной матрицы ($O(n^3)$ от числа признаков)
- Обратная матрица может быть вырожденной или плохо обусловленной
- Если заменить среднеквадратичный функционал ошибки на другой, то аналитическое решение может не найтись



Выход – метод градиентного спуска

- Вам о нем рассказывал Лагутин...
- Главная идея – в том, что у функции есть градиент: вектор, в направлении которого функция быстрее всего растет.
- Чтобы найти минимум функции, нужно двигаться в противоположную сторону.
- Тут придется считать производные...



Как это работает

- Инициализируем веса рандомом
- Считаем частные производные для каждого веса
- Если вычесть из веса его частную производную, то вес сдвинется в нужную сторону
- Добиваемся того, что изменения становятся слишком незначительными или вообще перестают происходить – вуаля! Мы в минимуме (возможно, локальном...)




Градиентный спуск бывает:

- Обычный
- Стохастический:
 - на каждом шаге выбираем случайный элемент выборки, вычисляем веса на нем и двигаемся в его сторону
- Mini-batch:
 - выбираем партию случайных элементов (батч) и вычисляем производные только для них



Как это все выглядит:



Градиентный спуск не единственный.

- Модификации градиентного спуска:
 - ADAGRAD
 - Adam
 - Adadelta
 - SGDm – модификация SGD
- RMSPROP
- Метод моментов

Подробнее тут:

http://www.machinelearning.ru/wiki/images/a/a0/2016_417_ChabanenkoVD.pdf



Как оценить качество модели?

- Два способа оценивать качество (любой) модели:
 - смотреть глазками
 - считать циферки
- Для регрессии метрики одни, для классификации - другие



Функционал ошибки и метрики качества

- Функционал (функция) ошибки – функция, которую мы минимизируем, когда обучаем модель
- Метрика качества – функция, которая позволяет оценить уже обученную модель

Функции могут совпадать, но вы не путайте!



Метрики качества. Регрессия

- Какую уже знаете?



Метрики качества. Регрессия

- MSE

$$\text{MSE} = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

Плюсы:

- подходит для сравнения моделей
- можно контролировать качество во время обучения

Минусы:

- плохо интерпретируется (нужно корень извлекать, чтобы вернуться к тем же единицам измерения)
- не ограничена сверху, как понять, когда качество идеальное?



Метрики качества. Регрессия

- MSE
- RMSE = root mean squared error

$$RMSE(a, X) = \sqrt{\frac{1}{l} \sum_{i=1}^l (a(x_i) - y_i)^2}$$

Плюсы:

- подходит для сравнения моделей
- можно контролировать качество во время обучения
- сохраняет единицы измерения

Минусы:

- не ограничена сверху, как понять, когда качество идеальное?



Метрики качества. Регрессия

- MSE
- RMSE
- MAE (mean absolute error)

$$MAE(a, X) = \frac{1}{l} \sum_{i=1}^l |a(x_i) - y_i|$$

Плюсы:

- менее чувствителен к выбросам, чем MSE

Минусы:

- нельзя брать производные
- тоже не ограничен сверху



Метрики качества. Регрессия

- MSE
- RMSE
- MAE
- R2 (коэффициент детерминации)

$$R^2(a, X) = 1 - \frac{\sum_{i=1}^l (a(x_i) - y_i)^2}{\sum_{i=1}^l (y_i - \bar{y})^2}$$

Коэффициент детерминации – это квадрат коэффициента корреляции выборки. Коэффициент детерминации оценивает долю дисперсии (изменчивости) Y , которая объясняется с помощью X в простой линейной регрессионной модели.

Чем ближе к 1, тем лучше; если близко к 0, то плохо, если отрицательный – вс чн плх



Метрики качества. Регрессия

- MSE
- RMSE
- MAE
- R2
- MSLE = логарифмический

Подходит для задач с неотрицательной целевой переменной
Штрафует за отклонения в порядке величин
Штрафует заниженные прогнозы сильнее, чем завышенные

$$MSLE(a, X) = \frac{1}{l} \sum_{i=1}^l (\log(a(x_i) + 1) - \log(y + 1))^2$$



Метрики качества. Регрессия

- MSE
- RMSE
- MAE
- R2
- MSLE
- MAPE (mean absolute percentage error)

Плюсы:

- ограничена от 0 до 1
- хорошо объясняет (в процентах ошибки)

Минусы:

- по-разному относится к недо- и перепрогнозу, больше котирует недопрогнозы

$$MAPE(a, X) = \frac{1}{l} \sum_{i=1}^l \frac{|y_i - a(x_i)|}{|y_i|}$$



Метрики качества. Регрессия

- MSE
- RMSE
- MAE
- R2
- MSLE
- MAPE
- SMAPE

$$SMAPE(a, X) = \frac{1}{l} \sum_{i=1}^l \frac{|y_i - a(x_i)|}{(|y_i| + |a(x_i)|)/2}$$

Симметричный мапе: попытка уравновесить недо- и перепрогнозы. Хотя теперь они более близки, но все-таки не равны. Есть мнение, что смапе (как и мапе) – так себе метрика.

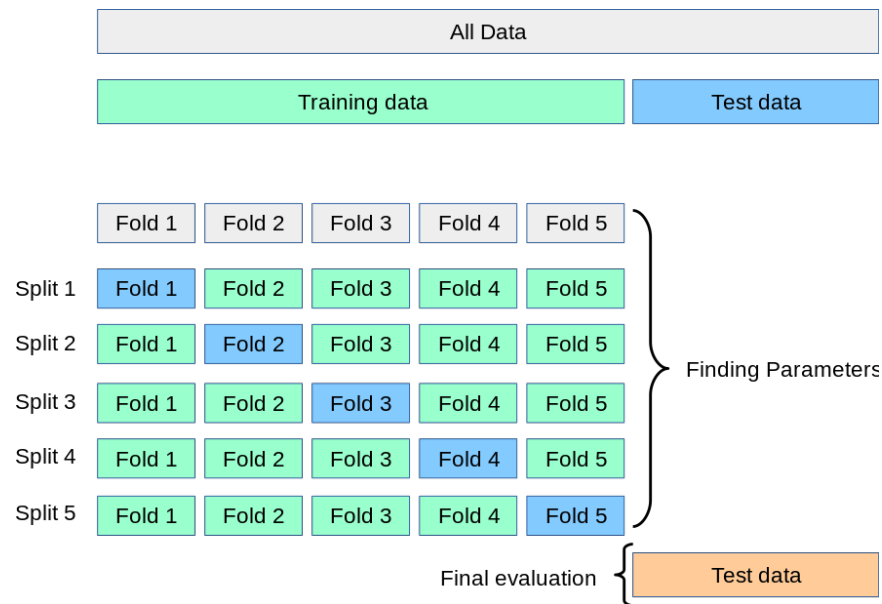
Как думаете, какая метрика самая клевая?



Кросс-валидация

(проверка на понимание)

- Разбиваем выборку на трейн и тест **несколько раз**.
- Сколько раз разбили, столько и фолдов.



Регуляризация

- Какие знаете признаки переобучения модели?



Регуляризация

- Признаки переобучения модели:
 - слишком разное качество на train и test
 - слишком большие значения весов
 - причиной больших значений весов могут быть линейно-зависимые фичи
- Как бороться? Регуляризацией!
- Регуляризация штрафует за слишком большие веса



Регуляризация

$$Q_{alpha}(w) = Q(w) + \alpha \cdot R(w) \rightarrow \min_w$$


$R(w)$ – это регуляризатор (тоже какая-то функция), α – параметр регуляризации (большое α сильно учитывает регуляризацию, маленькое нет)

- L1-регуляризатор: $R(w) = ||w||_1 = \sum_{i=1}^d |w_i|$
- L2-регуляризатор: $R(w) = ||w||_2 = \sum_{i=1}^d w_i^2$
- (то есть, L1 – сумма модулей весов, а L2 – сумма их квадратов)



Как это работает?

- L1 зануляет незначительные признаки => естественный отбор фич! (Не всегда хорошо)
- Картинка для ситуации, когда у нас всего 2 веса ----->



Как это работает?

- L2 не зануляет незначительные признаки, но делает их близкими нулю
- Картинка для ситуации, когда у нас всего 2 веса ----->

