

Линейная классификация

Занятие 4

Линейная модель

Повторим

$x - ? \ (x_1, x_2, \dots, x_n - ?)$

$y - ?$

Линейная модель

Повторим

x - объект (x_1, x_2, \dots, x_n - признаки)

y - ответ (целевая переменная)

Линейная модель

Повторим

х - объект (x_1, x_2, \dots, x_n - признаки)

у - ответ (целевая переменная)

Модель линейной регрессии: ответ складывается из ...?

$$a(\mathbf{x}, \mathbf{w}) = \sum_{i=1}^l w_j x_j$$

Линейная модель

Повторим

х - объект (x_1, x_2, \dots, x_n - признаки)

у - ответ (целевая переменная)

Модель линейной регрессии:

ответ складывается из суммы «признаки» * «веса»

$$a(x, w) = \sum_{i=1}^l w_j x_j$$

Линейная модель

Повторим

Метод обучения (минимизируем разницу между предсказанием и правильным ответом) – с помощью чего?

Линейная модель

Повторим

Метод обучения (минимизируем разницу между предсказанием и правильным ответом) - MSE

$$Q(a, X) = \frac{1}{\ell} \sum_{i=1}^{\ell} (a(x_i) - y_i)^2$$

Линейная модель

Повторим

x - объект (x_1, x_2, \dots, x_n - признаки)

y - ответ (целевая переменная)

Модель линейной регрессии: ответ складывается из суммы «признаки» * «веса»


$$a(\mathbf{x}, \mathbf{w}) = \sum_{i=1}^l w_j x_j$$

Метод обучения (минимизируем разницу между предсказанием и правильным ответом) с помощью MSE

$$Q(a, X) = \frac{1}{\ell} \sum_{i=1}^{\ell} (a(x_i) - y_i)^2$$

Бинарная классификация

x_1	x_2	y
180	5	М
170	20	Ж
160	5	М
190	30	?




y_1, y_2, \dots, y_n - ответы
(только +1 или -1)

У нас на рисунке Ж
будет соответствовать
+1, а М -1

Бинарная классификация


x_1	x_2	y
180	5	м
170	20	ж
160	5	м
190	30	?



У нас на рисунке Ж будет соответствовать +1, а М -1
Можем ли мы использовать ту же формулу, что и в линейной регрессии, чтобы найти y ?

$$a(\mathbf{x}, \mathbf{w}) = \sum_{j=1}^l w_j x_j$$

Бинарная классификация



Можем ли мы использовать ту же формулу, что и в линейной регрессии, чтобы найти y ?

$$a(\mathbf{x}, \mathbf{w}) = \sum_{j=1}^l w_j x_j$$

Нет, она выдает произвольные числа. Нам не важно значение y , нужен только знак: - или +


Модель линейного классификатора

Подбираем веса для признаков так, чтобы объекты из одного класса имели вес со знаком +, а другого -


$$a(\mathbf{x}, \mathbf{w}) = \textcolor{red}{sign} \left(\sum_{j=1}^l w_j x_j \right)$$

Берем из этого только знак

Модель линейного классификатора




Линейный классификатор




Линейный классификатор

Геометрия

- Линейный классификатор проводит гиперплоскость
 - $\langle w, x \rangle < 0$ – объект «слева» от неё
 - $\langle w, x \rangle > 0$ – объект «справа» от неё



В 3-мерном случае



Обучение классификатора

Как обучить?

Обучение - минимизация доли ошибок классификатора:

$$Q(a, X) = \frac{1}{n} \sum_{i=1}^n [a(x_i) \neq y_i] \rightarrow \min$$

где $[a(x_i) \neq y_i] = 1$, если предсказание на объекте неверное, и 0, если верное.

Обучение классификатора

Как обучить?

Обучение - минимизация доли ошибок классификатора:

$$Q(a, X) = \frac{1}{n} \sum_{i=1}^n [a(x_i) \neq y_i] \rightarrow \min$$

где $[a(x_i) \neq y_i] = 1$, если предсказание на объекте неверное, и 0, если верное.

Делим кол-во ошибок на кол-во объектов. Получаем долю ошибок

Отступ классификатора (margin)

$$Q(a, X) = \frac{1}{n} \sum_{i=1}^n [a(x_i) \neq y_i] \rightarrow \min$$

Нам это не нравится

$M_i = y_i \cdot (w_i, x_i)$ - **отступ на i -м объекте.**

Если классификация неверная, какой будет знак здесь: $y_i \cdot (w_i, x_i)$?

Отступ классификатора (margin)

Если классификация неверная, знак $y_i \cdot (w_i, x_i)$ всегда будет **минус**

- Если наши множители имеют разный знак - М будет **отрицательный**
- Если наши множители одного знака - М будет **положительный**

Margin всегда отрицательный при ошибке

Обучение классификатора

$$Q(a, X) = \frac{1}{n} \sum_{i=1}^n [a(x_i) \neq y_i] \rightarrow \min$$


=

$$Q(a, X) = \frac{1}{n} \sum_{i=1}^n [M_i < 0] \rightarrow \min$$

Отступ классификатора (margin)

Абсолютная величина отступа M обозначает **степень уверенности классификатора в ответе** (чем ближе M к нулю, тем меньше уверенность в ответе)

Отступ = насколько мы далеко от разделяющей поверхности




Отступ

Ранжирование значений

Надёжные - большой положительный отступ

Пограничные - небольшой положит. или отрицательный

Шумовые - большой отрицательный (сильно ошиблись, выброс)



Линейная регрессия

Ну-ка вспомним


Как мы минимизировали ошибки в линейной регрессии?

Линейная регрессия

Ну-ка вспомним

Как мы минимизировали ошибки в линейной регрессии?

Находили **минимум функции MSE** с помощью градиентного спуска



Линейная классификация

Но в классификации у нас не MSE, а какие-то отступы...

$$Q(a, X) = \frac{1}{n} \sum_{i=1}^n [M_i < 0] \rightarrow \min$$


Что здесь минимизировать? **Пороговую функцию потерь**

Линейная классификация

Но в классификации у нас не MSE, а какие-то отступы...

$$Q(a, X) = \frac{1}{n} \sum_{i=1}^n [M_i < 0] \rightarrow \min$$

Что здесь минимизировать? **Пороговую функцию потерь.**
Но она разрывна! Тут никакого градиентного спуска...



Функция потерь

Вместо пороговой функции потерь придется взять **другую, гладкую (непрерывную)**, чтобы от нее считать производные.

Взять может не любую функцию, а такую, которая будет ограничивать нашу функцию сверху

Функция потерь

Вместо пороговой функции потерь придется взять **другую, гладкую (непрерывную)**, чтобы от нее считать производные.

Взять может не любую функцию, а такую, которая будет ограничивать нашу функцию сверху




Рис. 7. Непрерывные аппроксимации пороговой функции потерь [$M < 0$].

- | | |
|-----------------------------|---------------------|
| $Q(M) = (1 - M)^2$ | — квадратичная; |
| $V(M) = (1 - M)_+$ | — кусочно-линейная; |
| $S(M) = 2(1 + e^M)^{-1}$ | — сигмоидная; |
| $L(M) = \log_2(1 + e^{-M})$ | — логистическая; |
| $E(M) = e^{-M}$ | — экспоненциальная. |

Функция потерь

Вместо пороговой функции потерь придется взять **другую, гладкую (непрерывную)**, чтобы от нее считать производные.

Взять может не любую функцию, а такую, которая будет ограничивать нашу функцию сверху

В зависимости от взятой функции потерь мы получим **разные ответы, это разные классификаторы**.

Функция потерь

В зависимости от функции мы получаем какую-то модель. Например, с помощью логистической функции потерь - логистическую регрессию




Рис. 7. Непрерывные аппроксимации пороговой функции потерь [$M < 0$].

- | | |
|-----------------------------|---------------------|
| $Q(M) = (1 - M)^2$ | — квадратичная; |
| $V(M) = (1 - M)_+$ | — кусочно-линейная; |
| $S(M) = 2(1 + e^M)^{-1}$ | — сигмоидная; |
| $L(M) = \log_2(1 + e^{-M})$ | — логистическая; |
| $E(M) = e^{-M}$ | — экспоненциальная. |

Повторим

1. Мы не можем использовать для классификации функцию линейной регрессии. Вместо этого мы берем знак (sign)

$$a(\mathbf{x}, \mathbf{w}) = \sum_{i=1}^l w_j x_j \longrightarrow a(\mathbf{x}, \mathbf{w}) = \text{sign} \left(\sum_{j=1}^l w_j x_j \right)$$

2. Тогда наша функция потерь такая: $Q(a, X) = \frac{1}{n} \sum_{i=1}^n [\mathbf{M}_i < 0] \rightarrow \min$
Но она пороговая.

Придется брать аппроксимирующую функцию.

Повторим

3. Апроксимирующая функция должна ограничивать нашу пороговую сверху. Этому условию удовлетворяет несколько функций.


В зависимости от функции, мы получим разные ответы. След., разные классификаторы

4. Ура, классификатор обучен! Он умеет выдавать ответы для новых данных. **Как понять, хороший ли у нас классификатор?**

Метрики качества


Метрика качества классификации

Accuracy



Метрика качества классификации

Accuracy



Метрика качества классификации

Accuracy

Плюсы:

- просто считать
- очевидно

Минусы?

Метрика качества классификации

Accuracy

Плюсы:

- просто считать
- очевидно

Минусы:

При несбалансированных классах плохо отражает
качество алгоритма.

Метрика качества классификации

Задачка


Пример: Кредитный scoring.

Выборка из 200 клиентов, 100 вернули, 100 не вернули

Модель 1: одобряет 100 кредитов

80 кредитов вернули

20 кредитов не вернули



Модель 2: одобряет 50 кредитов

48 кредитов вернули

2 кредита не вернули

Какая лучше?

Матрица ошибок

		True Class	
		Positive	Negative
Predicted Class	Positive	TP	FP
	Negative	FN	TN


Precision, Recall

Точность (precision):

$$Precision(a, X) = \frac{TP}{TP + FP}$$

Полнота (recall):

$$Recall(a, X) = \frac{TP}{TP + FN}$$



How many retrieved items are relevant?

$$\text{Precision} = \frac{\text{green}}{\text{green} + \text{red}}$$

How many relevant items are retrieved?

$$\text{Recall} = \frac{\text{green}}{\text{green} + \text{yellow}}$$

Precision

Модель $a_1(x)$:

$$\text{precision}(a_1, X) = 0.8$$

		$y = 1$ Могут вернуть	$y = -1$ Не могут вернуть
$a(x) = 1$ Получили кредит	80	20	
	20	80	

Модель $a_2(x)$:

$$\text{precision}(a_2, X) = 0.96$$

		$y = 1$ Могут вернуть	$y = -1$ Не могут вернуть
$a(x) = 1$ Получили кредит	48	2	
	52	98	

Recall

Модель $a_1(x)$:

$$\text{recall}(a_1, X) = 0.8$$

	$y = 1$ Могут вернуть	$y = -1$ Не могут вернуть
$a(\mathbf{x}) = 1$ Получили кредит	80	20
$a(\mathbf{x}) = -1$ Не получили кредит	20	80

Модель $a_2(x)$:

$$\text{recall}(a_2, X) = 0.48$$

	$y = 1$ Могут вернуть	$y = -1$ Не могут вернуть
$a(\mathbf{x}) = 1$ Получили кредит	48	2
$a(\mathbf{x}) = -1$ Не получили кредит	52	98

F-мера

F-мера учитывает и точность, и полноту

